

 Cada año se producen 1,9 millones de muertes como consecuencia de accidentes de tráfico; En 2022, habrá 1.175 muertes por accidentes de tráfico en Nueva York



JUAN MANUEL LOPEZ RODRIGUEZ (2226066)

WILLIAM ALEJANDRO BOTERO FLOREZ (2225155)

### TABLA DE CONTENIDO

- Objetivo del Proyecto
- Herramientas Utilizadas
- WorkFlow
- Accidents in USA (DataBase)
- Data Cleaning (Database)
- New York Data (Extract API)
- Data Cleaning (API)

- Merge Entre las bases de Datos
- Data Cleaning (Merged Data)
- Final Data
- Data Analysis
- Airflow
- Dimensional Model
- Data Dashboard

### OBJETIVO DEL PROYECTO

Realizar el análisis de datos de nuestras bases proporcionadas juntas, las cuales tienen datos muchos más completos y estructurados, que nos permitan visualizar la distribución de estos para un mejor entendimiento del contexto



## USED TOOLS




- PYTHON
- PANDAS
- AIRFLOW
- POSTGRES
- KAGGLE
- POWER BI











### ACCIDENTS IN USA:

Para la obtención de los datos, los extrajimos desde la pagina de Kaggle, sobre el dataset de "US Accidents (2016-2023)", el cual nos da información sobre accidentes de tránsito que ocurrieron en Estados Unidos entre 2016 y 2023.

Una vez, descargados los datos, los subimos a la base de datos

Postre: V Tables (2) la conexió y los ( ) merged

✓ ■ us\_accidents
✓ ■ Columns (46)

 Una vez subida la base de datos a PostGres, importamos los datos a nuestro entorno de trabajo, para empezar a realizar todos lo

```
# Establish a connection and create a cursor

conn, cursor = establecer_conexion() # Function to establish the database connection

# SQL query to select all data from the 'us_accidents' table

query = "SELECT * FROM us_accidents"

# Read the data into a pandas DataFrame

df = pd.read_sql_query(query, conn)

Conexion exitosa a la base de datos
```

# DATA CLEANING (DATABASE)

• Para la limpieza de datos, lo que hicimos fue identificar datos nulos, patrones repetidos, columnas que no dieran información relevante que se puedan borrar y rellenar datos nulos con una imputación de datos.

```
columns to drop = ['id', 'source', 'country', 'description', 'end_lat', 'end_lng',
                 'civil_twilight', 'nautical_twilight', 'astronomical_twilight']
# Drop the specified columns
df_cleaned = df.drop(columns=columns_to_drop)
# Impute missing values in numerical columns with the mean
df_cleaned['temperature_f'].fillna(df_cleaned['temperature_f'].mean(), inplace=True)
# Impute missing values in categorical columns with the mode (most frequent value)
df cleaned['weather condition'].fillma(df cleaned['weather condition'].mode()[0], inplace=True)
# Impute missing values in multiple numerical columns with the mean
num_cols = ['wind_chill_f', 'humidity_percent', 'pressure_in', 'visibility_ni', 'wind_speed_mph', 'precipitation_i
df cleaned[num cols] - df cleaned[num cols].apply(lambda col: col.fillna(col.mean()))
# Impute the 'wind direction' column with the most frequent value (mode)
df_cleaned['wind_direction'] = df_cleaned['wind_direction'].fillna(df_cleaned['wind_direction'].mode()(0])
# Impute 'weather timestamp' with the previous value (forward fill) for missing timestamps
df_cleaned['weather_timestamp'] = df_cleaned['weather_timestamp'].fillna(method='ffill')
# Hemove rows containing any remaining missing values
 f_cleaned.dropna(inplace=True)
```

### NEW YORK DATA

- Tomando una parte más pequeña del país, decidimos enfocarnos en solo los accidentes que ocurren en la ciudad de Nueva York, así, tomamos los datos de la siguiente API:
  - https://data.cityofnewyork.us/resource/ h9gi-nx95.json
- La API, tiene una restricción de 1000 datos, por lo cual, al momento de consumirla, decidimos generar unos parámetros, para que, en vez de traer

```
# URL of the dataset (API endpoint)
url = "https://data.cityofnewyork.us/resource/h9gi-nx95.json"

# Parameters to limit the response to 200,000 records
params = {
    "$limit": 200000
}

# Send a GET request to the API
response = requests.get(url, params=params)
```

#### • DATA API:

• Estas columnas, nos dan una vista previa de que datos podremos usar para poder realizar el merge con nuestra base de datos, y así, tener nuevos datos más completos.

# DATA CLEANING (API)

```
# Get the absolute path of the file
file path = os.path.abspath(os.path.join('../data/API data.csv'))
# Load the CSV file using pandas
data = pd.read_csv(file_path)
# Set pandas to display all columns
pd.set_option('display.max_columns', None)
# 2. Convert 'crash date' and 'crash time' to datetime format
# Handle errors by setting invalid parsing as NaT (Not a Time)
data['crash_date'] = pd.to_datetime(data['crash_date'], errors='coerce')
data['crash_time'] = pd.to_datetime(data['crash_time'], format='%H:%M', errors='coerce')
data['borough'] = data['borough'].str.strip().str.title()
# Filter data to keep only rows with valid crash dates and from the year 2821 or later
data = data[data['crash_date'].notna() & (data['crash_date'].dt.year >= 2821)]
W 4. Remove duplicates based on the "collision_id" column (assuming it's unique for each accident)
data = data.drop_duplicates(subset='collision_id')
# Convert "crash_date" to just the date (drop the time part)
data['crash_date'] = data['crash_date'].dt.date
# Drop unnecessary columns
data = data.drop(['vehicle_type_code_5', 'contributing factor_vehicle_5',
                  'vehicle_type_code_4', 'contributing_factor_vehicle_4',
                   'vehicle_type_code_3', 'contributing_factor_vehicle_3',
                  'cross street name'], axis-1)
print("FILTERED AND CLEANED DATA: \")
# Drop rows with any missing values
data - data.dropna()
data['city'] = "New York"
```

• Para la limpieza de la API, hicimos un proceso muy parecido al anterior, además de hacer una estandarización de los datos, elegir el formato correcto de las columnas relacionadas con fechas, quardar los datos que se registraron a partir del año 2021, ya que en los años anteriores se contaba con muy poquitos registros que generaban datos atípicos y por ultimo, crear una columna que se llamara ciudad, en la cual para todas las filas iban a ser iquales a New York, ya que esto nos iba a facilitar el proceso de hacer el Merge entre las 2 bases de datos.

### MERGE ENTRE BASES DE DATOS

• Para la mezcla entre amabas bases de datos, lo que hicimos fue realizarlo mediante la fecha del hecho, donde concordará el día y la hora en donde ocurrió el accidente, además se aplicó un filtro donde solo nos trajera los accidentes que ocurrieron en New York, principalmente en la hase de datos quardada en PostgreSOL para ter API\_merge = pd.read\_csv('../data/API\_data\_Cleaned.csv') cla

```
db_merge = pd.read_csv('../data/AFI_data_Cleaned.csv')

# Convert date columns to datetime format and use only the date
API_merge['crash_date'] = pd.to_datetime(API_merge['crash_date']).dt.date # Use only the date
db_merge['start_time'] = pd.to_datetime(db_merge['start_time']).dt.date # Use only the date

# Filter both datasets for rows where the city is 'New York'
api_data_ny = API_merge[API_merge['city'] == 'New York']
us_accidents_ny = db_merge[db_merge['city'] == 'New York']

# Merge the two datasets based on the date (inner join)
merged_df = pd.merge(api_data_ny, us_accidents_ny, left_on='crash_date', right_on='start_time', how='inner')
```

# DATA CLEANING (MERGED DATA)

• Para la limpieza de los datos ya hecho el merge, se identificaron patrones repetidos, eliminamos columnas no importantes, eliminamos columnas repetidas que salieron a partir del merge, conversión de formatos de fechas, conversión de columnas flotantes a enteros, mezcla entre columnas para información más completa y estandarización de

```
# 3. Berrar 'Colishion_id'
merged_df.drop(columns=['collision_id'], implace=True)

# 4. Berrar 'Factor contributyente 2'
merged_df.drop(columns=['contributing_factor_vehicle_2'], implace=True)

# 5. Berrar 'vehicle_type_tode2'
merged_df.drop(columns=['vehiclo_type_code2'], implace=True)

# 6. Mezclar 'codigo_postal' con 'distrito'

# 5upongamos que 'codigo_postal' y 'distrito' son las columnas en merged_clean
merged_df['borough'] = merged_df['borough'] + ' - ' + merged_df['zip_code'].astype(str)

# 8. Berrar 'start time' y 'end time'
merged_df.drop(columns=['start_time', 'end_time'], implace=True)

# 9. Berrar 'start latitud' y 'end latitud'
merged_df.drop(columns=['start_lat', 'start_ing'], implace=True)

# 10. Berrar 'distancia en millas'
merged_df.drop(columns=['distance_mi'], implace=True)

# 11. Berrar 'county'
merged_df.drop(columns=['county'], implace=True)

# 12. Mezclar 'state' con 'city'
merged_df['city'] = merged_df['city'] + ', ' + merged_df['state']
```

### FINAL DATA

• Luego de realizar toda la limpieza necesaria al merge de las bases de datos, quedamos con la base de datos final la cual nos habla solamente de Accidentes en la ciudad de New York, información a la cual le haremos todo lo relacionado al análisis



#### Distribution by type of vehicle

Comparison between day and night accidents involved:

Comparison between day and night accidents:
sunrise\_sunset
Day 31947
Night 15277

Relationship between weather conditions and

Relationship between climate and number of injured people: weather\_condition Fair 17746 Cloudy 6142 Light Rain 1807 Mostly Cloudy 1760 Partly Cloudy 1310 Heavy Rain 293 261 Rain Fog 149 Light Snow 128 Haze 64 15 Snow

#### vehicle type code1 Sedan 22405 Station Wagon/Sport Utility Vehicle 16225 1386 Taxi Bus 1099 Pick-up Truck 1003 TRACTOR Commercial MTA bus REFG Van Camper

#### Distribution by time of

2. D	istribution	by time	of	day:	
	crash_time	count			
0	00:00	690			
828	14:00	457			
888	15:00	440			
1008	17:00	413			
768	13:00	398			
226	03:48	1			
283	04:47	1			
233	03:56	1			
234	03:57	1			
275	04:38	1			

# Most common contributing factors in serious accidents

Most common contributing factors in serious accidents: contributing factor vehicle 1	
Driver Inattention/Distraction	5855
Unspecified	3572
Failure to Yield Right-of-Way	2820
Traffic Control Disregarded	1733
Following Too Closely	1218
Unsafe Speed	820
Passing or Lane Usage Improper	757
Turning Improperly	623
Other Vehicular	490
Pedestrian/Bicyclist/Other Pedestrian Error/Confusion	431
Driver Inexperience	366
Unsafe Lane Changing	334
Alcohol Involvement	317
View Obstructed/Limited	301

### Accidents by

Accidents by (borough):		
borough		
Brooklyn - 11207.0	1427	
Brooklyn - 11236.0	922	
Brooklyn - 11234.0	831	
Queens - 11434.0	771	
Brooklyn - 11208.0	758	
Manhattan - 10280.0	5	
Manhattan - 10115.0	4	
Manhattan - 10069.0	4	
Queens - 11109.0	2	
Manhattan - 10169.0	1	
	borough Brooklyn - 11207.0 Brooklyn - 11236.0 Brooklyn - 11234.0 Queens - 11434.0 Brooklyn - 11208.0 Manhattan - 10280.0 Manhattan - 10115.0 Manhattan - 10069.0 Queens - 11109.0	

# Correlation between type of vehicle and number of

Correlation between type of vehicle	and number of injured people:
vehicle_type_code1	
Sedan	14633
Station Wagon/Sport Utility Vehicle	10300
Taxi	971
Bike	617
Pick-up Truck	536
	***
MINIVAN	Ð
MINI BUS	Ð
Lunch Wagon	Ð
LOCOMOTIVE	Ð
van	ð.

#### Accidents by Wind Speed

Accidents by	Wind Speed:
wind speed m	
	9099
3.000000	8589
5.000000	7806
6.000000	7099
7.000000	3737
7.681347	2513
8.000000	2403
9.000000	2011
10.000000	1356
13.000000	709
12.000000	685
15.000000	416
18.000000	308
16.000000	306
14.000000	187

Comparison between Injured Persons, Pedestrians, Cyclist and Motorist

```
Comparison between injured pedestrians, cyclists and motorcyclists:
{'Injured People': 29675, 'Injured Pedestrians': 219, 'Injured Cyclist': 4104, 'Injured Motorist': 23444}
```


# Most common factors in accidents without

Most common factors in accidents without injuri contributing factor vehicle 1	es:
Driver Inattention/Distraction	6780
Unspecified	4674
Failure to Yield Right-of-Way	1879
Passing or Lane Usage Improper	1701
Following Too Closely	1582
Passing Too Closely	1239
Traffic Control Disregarded	1091
Turning Improperly	1040
Backing Unsafely	911
Unsafe Speed	789
Other Vehicular	690
Alcohol Involvement	591
Driver Inexperience	545
Unsafe Lane Changing	530
Reaction to Uninvolved Vehicle	323


# Correlation between temperature and number of


accidents	
Correlation between type of vehicle	and number of injured people:
vehicle_type_code1	
Sedan	14633
Station Wagon/Sport Utility Vehicle	10300
Taxi	971
Bike	617
Pick-up Truck	536
	***
MINIVAN	0
MINI BUS	e
Lunch Wagon	Ð
LOCOMOTIVE	Ð

# AIRFLOW



### DIMENSIONAL MODEL







TOTAL ACCIDENTS



